

Sieve 拒稿后重构

第二阶段： 实验补强计划

针对“结果过于不成熟”意见的三路径补强：端到端评估扩容
($n=100 \rightarrow 300$)、三阅读器稳健性与位置剖面重测、跨数据集消融与统一实
验矩阵——含 research-repo 逐脚本对接清单与完成定义映射表。

Super Z 研究助手

配套文档：第一阶段《Novelty 审计报告》(叙事重构已完成于 paper-journal-v2)
对象仓库：GitHub 43aquaris/academic-paper

目录

1 拒稿诊断与本计划的任务	2
2 现状资产盘点	2
2.1 选择器层资产（成熟，无需改动）	3
2.2 端到端层资产（协议在、数据缺）	3
2.3 缺口清单（本计划要补的）	3
3 路径 A：端到端评估扩容	3
3.1 A0：恢复执行已发布的 $n=100$ 协议（P0，零新工程）	3
3.2 A1：扩容到 $n=300$ （P1）	4
3.3 A2：跨数据集端到端（P2，视资源）	4
3.4 A3：结果表格模板（先于实验固定）	4
4 路径 B：阅读器多样性与位置剖面重测	5
4.1 B1：阅读器选择（P2）	5
4.2 B2：阅读器侧位置剖面重测（P2，低成本高杠杆）	5
4.3 B3：与相关研究的合并	5
5 路径 C：消融矩阵与统一实验矩阵（P1，纯本地计算）	6
5.1 C1：组件消融跨数据集（改动量最小、收益直接）	6
5.2 C2：配置 $\times$ 预算交叉矩阵	6
5.3 C3：frontier 图升级	6
5.4 C4：可选——预算自适应实验（formulation 的自然延伸）	6
6 统一实验矩阵、优先级与执行顺序	7
7 research-repo 对接清单	7
8 声明纪律与负结果报告规范	8
9 完成定义：拒稿意见逐条映射	9

1 拒稿诊断与本计划的任务

IP&M 拒稿意见的第二句是：所报告的研究结果过于不成熟（the research results reported are too premature for publication），并要求补充更多工作以支撑论文结论（more work is needed to substantiate the conclusions）。与第一句（新颖性）不同，这一意见指向证据链本身，而且它在论文的局限一节里可以逐条对上号。把局限一节的五条边界与拒稿意见对照阅读，可以精确拆出“premature”的三个具体构成。

其一，端到端证据的规模失衡。选择器层面的评估是 1,600 条记录、六个选择器、分离的配对区间——这一层是成熟的；但端到端问答只有单一阅读器（GLM-4-Plus）、单一数据集（QASPER）、单一操作点（4×）、 $n=25$ ，其配对 F1 差的 95% 区间为 $[-14.5, 8.2]$ ，半宽超过 ± 11 个 F1 点。任何关于端到端效应的实质性主张（例如“Sieve 与截断统计持平”）在这个区间宽度下都只能是方向性陈述，而编辑与审稿人读到的是“前层实验充分、终层实验示踪”的观感。其二，机制消融未连成矩阵。组件消融（去问题条件化、平位置先验、去冗余惩罚、纯相关性）目前只在 QASPER 单数据集上运行，且与预算扫描、位置研究、效率测量各自成节，没有形成“预算 × 配置 × 指标 × 数据集”的统一矩阵，读者无法直接看到三个选择目标在整个预算范围内的交换率。其三，结论的单点依赖。论文的核心叙事——不同选择目标产生结构性权衡——目前依赖单一阅读器的间接证据（召回-F1 相关性 $n=25$ /方法），缺少跨阅读器的稳健性背书。

本计划给出三条互补的补强路径，分别对准上述三个构成：路径 A 扩大端到端评估（最高优先级，直接回应“premature”）；路径 B 引入阅读器多样性并重测阅读器侧位置剖面（回应单点依赖与借用的位置剖面）；路径 C 把消融扩展成跨数据集统一矩阵（纯本地计算、零 API 依赖、成本最低）。三条路径与第一阶段的 novelty 重构严格对齐：第一阶段的结论是论文的新颖性由“formulation + frontier 方法论 + 结构性权衡发现”三根支柱承担，因此实验补强的目标不是让 Sieve 在任何指标上击败所有基线——那既不可能也不必要——而是让三根支柱的每一句声明都有相称规模的证据。负结果（例如 BM25 召回更高）在新的矩阵里应被更清晰地呈现为权衡点而非失败，这正是实验设计与写作纪律的结合处，第 8 节单独规定。

执行顺序遵循两个原则。第一，先便宜后昂贵：路径 C 全部为本地 CPU 计算（仓库现有 M 系列脚本的小改），路径 A 第一步是恢复执行已实现并发布的 $n=100$ 协议（脚本已带断点续跑），只有 A2/A3 与路径 B 需要新的 API 预算或 GPU。第二，先支撑后扩展：所有实验先在既有数据集与操作点上把声明的置信区间收紧，再考虑新数据集、新阅读器等增量维度；每一步的完成定义（第 9 节）都映射回拒稿意见的具体条目，避免“多跑实验”式的盲目扩容。

2 现状资产盘点

补强计划必须建立在对已有资产的精确盘点上，避免重复实现或误判工作量。以下盘点全部来自对 research-repo 的直接检视（文件与脚本头部注释），非转述。

2.1 选择器层资产（成熟，无需改动）

数据与池：`scripts/build_pools.py` 与 `download_data.py` 以固定种子构建三个评估池（QASPER 1,000、HotpotQA 300、2WikiMultihopQA 300，共 1,600 条证据标注记录）。选择器实现：`src/sieve/` 五个模块（分句、分词、打分、选择、压缩），基线在 `baselines/baselines.py` 单文件内（head、random、stride、TextRank、BM25）。本地分析：`scripts/run_journal_analysis.py` 实现七个分析任务 M1–M7——M1 主表、M2 预算扫描（ $r \in \{2, 4, 8, 16\}$ ，五种选择器）、M3 组件消融（目前限 QASPER）、M4 证据位置研究、M5 超参敏感性网格、M6 池统计、M7 逐记录召回导出（供相关研究用）——全部纯本地计算，无 LLM 调用。神经门：`scripts/run_gpt2_gate.py` 已在 100 条 QASPER 记录上完成测量（召回 28.7%，延迟与成本对照齐备）。时序与投影：`run_timing_journal.py` 与 `run_projection.py`。这一层的数字以 `make_numbers_journal.py` 生成 `numbers.tex` 宏，论文引用纪律已有保障。

2.2 端到端层资产（协议在、数据缺）

$n=25$ 的会议版端到端评估由 `run_api_experiment.py` 完成。关键资产是 $n=100$ 扩容协议：`scripts/run_qa_expanded.py` 已实现并随仓库发布，其头部文档明确记载——七个方法（full/head/random/stride/texttrank/bm25/sieve）在 $r=4$ 操作点；测试集为重建召回池的前 100 条 QASPER 记录（与 GPT-2 门完全同集，故逐记录召回与 F1 可精确连接做相关研究）；阅读器为同一生产 API（temperature 0、最多 96 个答案 token、最短片段指令）；断点续跑存于 `results/checkpoints/qa_expanded.jsonl`。配套的 `run_qa_driver.py` 是限流感知的驱动器：以时间窗口（默认 540 秒）为节奏推进，目标成功调用数默认 760（100 记录 $\times$ 7 方法 = 700，加失败重试余量），失败记录由断点机制自动补跑。也就是说，路径 A 的第一步不缺任何工程：论文局限一节所述“被持续限流阻塞”的任务，在 API 配额恢复后重新挂起驱动器即可继续。相关研究 `run_correlation.py` 已能把逐记录召回与 F1 合并。

2.3 缺口清单（本计划要补的）

对照三条 premature 构成，缺口精确为四项：其一， $n=100$ 端到端数据未落盘（阻塞因素是限流，非设计）；其二，端到端未扩展到 HotpotQA 与 2Wiki，也未越过 $n=100$ ；其三，组件消融被 M3 硬编码限制在 QASPER 池，且预算扫描（M2）与消融（M3）是分离的两个任务，没有“配置 $\times$ 预算”的交叉矩阵，GPT-2 门也未进入矩阵行；其四，阅读器只有一个，且阅读器侧位置剖面整段借用自 `liu2023lost` 而非在自建阅读器上重测。四项缺口分别由 A0/A1–A3、C1–C3、B1–B3 承接，下一章起逐条展开。

3 路径 A：端到端评估扩容

3.1 A0：恢复执行已发布的 $n=100$ 协议（P0，零新工程）

第一步不写任何新代码。直接挂起限流感知驱动器：`python3 scripts/run_qa_driver.py 540 760`（窗口 540 秒、目标 760 次成功调用），断点文件 `qa_expanded.jsonl` 会自动接续已

有进度。按头部文档记载的调用预算：总计 700 个方法-记录对 ($100 \text{ 记录} \times 7 \text{ 方法}$)，每问最多 96 个答案 token 加提示本身（中位上下文约 5,000 词，压缩后 $4 \times$ 约 1,250 词），合计输入 token 量级约 $700 \times 1,500 \approx 10^6$ 、输出 $700 \times 96 \approx 6.7 \times 10^4$ 。以当前生产 API 的计费量级，这是一次可一次性完成的预算；执行节奏由驱动器按限流自适应，建议在配额宽松时段连续挂机，断点机制保证中断无损失。

A0 完成后立即产出三件可写进修订稿的东西：其一， $n=100$ 的端到端主表（七方法 $\times$ EM/F1/保留率，附配对 bootstrap 区间），取代 $n=25$ 版本的示踪性区间；其二，BM25 首次进入端到端比较（ $n=25$ 版没有它），“结构性权衡”叙事由此获得端到端层的对应物——若 BM25 端到端与召回层同样领先，权衡叙事在两层一致；若不领先，则获得“召回优势不传导到答案质量”的第二类发现，同样有价值；其三，逐记录召回-F1 配对扩容到 $n=100$ （与门同集），相关系数的区间收窄约一半。

3.2 A1：扩容到 $n=300$ (P1)

样本量论证： $n=25$ 时 SIEVE-截断配对差的区间半宽约 ± 11.4 F1 点；配对区间半宽按 $1/\sqrt{n}$ 收缩， $n=100$ 时约 ± 5.7 ， $n=300$ 时约 ± 3.3 。若端到端效应真实存在于 ± 5 点的量级（召回层配对增益 12.8 点的合理传导折扣）， $n=300$ 是能以 95% 置信度分离它的最低规模；若区间仍然跨零，“统计持平”的主张便有了与其措辞相称的证据，同样构成完成。实现上只需把 `run_qa_expanded.py` 的测试集从“前 100 条”参数化为“前 300 条”（池本身有 1,000 条，无需重建），七方法不变、 $r=4$ 不变、提示与解码协议逐字不变——协议冻结是本路径的纪律：任何对提示模板、温度、答案长度约束的改动都会使新旧数据不可合并。预算为 A0 的三倍量级，仍属单次可完成。

3.3 A2：跨数据集端到端 (P2，视资源)

在 HotpotQA 与 2WikiMultihopQA 池上各抽 $n=100$ （各池均有 300 条，抽样种子固定并登记）。这两池的上下文是多文档拼接而非单篇论文，端到端行为可能与 QASPER 不同——多跳问题在 $4 \times$ 压缩下可能更脆弱，而这正是“problem formulation”声明（词汇信号强度决定问题条件化的收益）在端到端层的直接检验点。方法集可精简为四种（full/head/bm25/sieve）以控制预算：full 与 head 定义端到端上下界，bm25 与 sieve 是权衡叙事的两个端点，random/stride/texttrank 在 $n=100$ 下的区分度不足，省去。预算约为 A0 的两倍（ $2 \times 100 \times 4 = 800$ 对）。

3.4 A3：结果表格模板（先于实验固定）

端到端主表在跑数之前先定格式并冻结列含义：行为方法（full context、head、random、stride、texttrank、bm25、sieve），列为 EM、F1、full-context F1 保留率、输入 token 中位数；区间一律配对 bootstrap（1,000 重采样、95%），SIEVE 行与每个基线行的差值区间单独成列或成表。跨数据集扩展沿用同表式样。表格模板先行的作用是把“要报告什么”与“跑什么”解耦，避免事后挑数。

4 路径 B：阅读器多样性与位置剖面重测

4.1 B1：阅读器选择 (P2)

单一阅读器是“premature”观感的放大器：所有端到端结论都隐含“对 GLM-4-Plus 成立”的限定。补强目标是把结论升格为“SIEVE 作为前置选择器的行为具有跨阅读器趋势稳定性”——是趋势级主张，不是逐阅读器显著性主张，样本量与预算都按此设计。阅读器集建议三档：保留 GLM-4-Plus（既有数据的连续性锚点）；增加一个不同家族的旗舰 API 阅读器（例如 GPT-4o-mini 或 DeepSeek-V3 级，取当时可得且计费稳定者）；增加一个本地开源阅读器（Llama-3.1-8B-Instruct 或 Qwen2.5-7B-Instruct，经 vLLM 在单张消费级 GPU 上服务）。本地阅读器有双重价值：不受 API 限流（A0 的阻塞因素不再复现），且完全可复现——审稿人可以一字不差地重跑。

协议与 A 路径严格同构：同一池（QASPER 前 100 条）、同一方法集（七方法）、同一 $r=4$ 、同一提示模板与解码参数（temperature 0、96 token 上限）；唯一变量是阅读器端点。判定标准预先声明：跨三个阅读器，比较 SIEVE 相对 head 的 F1 保留率差（配对区间）与 bm25-sieve 的差——若三个阅读器上同号且量级同阶，趋势稳定成立；若出现异号，如实报告并讨论阅读器家族与压缩敏感性的交互，这本身即是可发表的结构发现。预算：每阅读器 700 对调用（API 档两项共 1.4×10^3 对，本地档仅 GPU 时租）。

4.2 B2：阅读器侧位置剖面重测 (P2，低成本高杠杆)

局限一节的第三条边界承认：U 形位置先验的依据是借自 liu2023lost 的阅读器侧剖面，而未在自己的阅读器上重测。补法是把论文 M4 位置研究的方向反过来：构造一组合成上下文（从池中抽取、把金证据句人工放置在 5 个相对位置 0/0.25/0.5/0.75/1——M4 脚本已实现该放置逻辑，方向相反），分别在三个阅读器上以 full-context 方式提问，记录答案 F1 随证据位置的曲线。每曲线 $5 \times n$ 次调用（ $n=50$ 已足够画出剖面），总预算数百次调用。产出直接回填两处写作：U 形先验的动机从“借用”升格为“自测”；若某阅读器剖面显著非 U 形（例如强中庸偏好），先验的 per-reader 校准即刻成为新实验方向——这是 formulation 框架自然生长出来的问题，恰是第一阶段要求的“问题形式化引领实验”的示范。

4.3 B3：与相关研究的合并

阅读器扩展后，召回-F1 相关研究（论文第八节）的样本从“一个阅读器 $\times$ 若干方法”升格为“三个阅读器 $\times$ 若干方法”，run_correlation.py 的合并逻辑无需改动，只需按阅读器分组重跑。若“弱相关”在三个阅读器上一致成立，“两种协议分开报告、永不合并”的方法论主张获得跨阅读器背书；若相关强度随阅读器显著变化，则获得第三类结构性发现（阅读器对证据召回的敏感度不同），并直接为下一版的讨论节提供素材。

5 路径 C：消融矩阵与统一实验矩阵 (P1, 纯本地计算)

5.1 C1：组件消融跨数据集（改动量最小、收益直接）

现状：M3 (`run_journal_analysis.py`) 把组件消融硬编码在 QASPER 池。改动：把消融配置从“QASPER only”参数化为三池循环（配置清单不变：全配置、 $\alpha=0$ 去问题条件化、 $\text{floor}=1$ 平位置先验、 $\beta=0$ 去冗余、纯相关性 $\alpha=1+$ 平先验 $+\beta=0$ ）。改动量约为该脚本内一个循环边界与结果分组的十几行；池文件、选择器实现、指标计算全部复用。产出：三数据集 $\times$ 五配置的消融表（每格证据召回加 bootstrap 区间）。预期与写作要点：HotpotQA 与 2Wiki 的问题实体命名更强，问题条件化的消融差应更大；位置先验在两 wiki 池上的“召回代价”可能不同于 QASPER（证据分布位置不同，M6 的池统计会给出预期方向）。无论方向如何，跨数据集一致的消融结构直接支撑“三目标是普遍机制而非单数据集偶然”的声明。

5.2 C2：配置 $\times$ 预算交叉矩阵

现状：M2 预算扫描只覆盖五种选择器 (`sieve/head/textrank/random/bm25`) 在 $r \in \{2, 4, 8, 16\}$ ；M3 消融只在 $r=4$ 。改动：把消融五配置加入预算扫描的循环体，形成“配置（5 消融 + 5 基线 + GPT-2 门） $\times$ 预算（4 档） $\times$ 数据集（3 池）”的完整召回矩阵；GPT-2 门复用已落盘的 100 条测量 ($r=4$ 单点)，不重跑。纯本地计算的总代价估算：每格一次选择器运行（毫秒级）加 bootstrap（1,000 重采样，秒级），全矩阵约 200 个“配置 $\times$ 预算 $\times$ 数据集”格，单容器数小时内完成。产出论文新表（或扩表现表）：每行一个配置，每列一个预算，报告召回与配对区间；配套把时序测量 (`run_timing_journal.py` 的既有数字）并入行属性，使每行天然携带“召回-压缩-成本”三元组——这正是三轴 frontier 图的数据源，C2 因此同时是效率节的补强。

5.3 C3：frontier 图升级

论文现有的 frontier 图 (fig4) 只画了少数点。C2 矩阵落盘后重绘：横轴选择成本（对数刻度，CPU ms 到 GPT-2 秒），纵轴证据召回（或端到端 F1 保留率，若 A 路径完成），同一预算的配置连成等预算线，三个数据集三张子图。预期图景：相关性族 (bm25、纯相关性消融、sieve 全配置的前半段) 聚在高召回带，全配置在等预算线上向“放置与多样性”方向位移，神经门在成本轴右端——三根支柱 (formulation、frontier、结构性权衡) 在同一张图上各自获得视觉证据。图重绘用 `fig_journal.py` 既有管线，改数据源即可。

5.4 C4：可选——预算自适应实验 (formulation 的自然延伸)

第一阶段审计确认“自适应预算”已被 AdaComp 占位（文档级、检索质量驱动）。若时间允许，可在 SIEVE 框架内做词预算随问题复杂度自适应的最小实验（例如按问题 token 数或查询词 IDF 和分桶调 B ），作为 formulation 的延伸而非新颖性主张——它证明三目标框架可以吸收预算维度，而与 AdaComp 的差异（句子级三目标 vs 文档级自适应）在 related work 已划定。此项不影响 DoD，仅在有余算力时执行。

6 统一实验矩阵、优先级与执行顺序

表 1: 补强实验统一矩阵。列为四类指标（证据召回、端到端质量、时延/成本、相关结构）；行为实验单元（选择器 × 配置 × 数据集 × 阅读器）。P0 必做、P1 强烈建议、P2 视资源；“本地”指纯 CPU 容器计算，“API”指阅读器调用。

实验	范围	指标	依赖	优先级	资源
C1 消融跨数据集	5 配置 × 3 池, $r=4$	召回 + 区间	无	P1	本地
C2 配置 × 预算矩阵	11 配置 × 4 预算 × 3 池	召回 + 区间	无	P1	本地
C3 frontier 重绘	C2 + 既有门测量	三轴	C2	P1	本地
A0 恢复 $n=100$	7 方法, QASPER, $r=4$	EM/F1/保留	API 配额	P0	API
A1 $n=300$	7 方法, QASPER, $r=4$	EM/F1/保留	A0	P1	API
A2 跨数据集 e2e	4 方法 × 2 池, $n=100$	EM/F1/保留	A0	P2	API
B1 多阅读器	7 方法 × 3 阅读器, $n=100$	EM/F1	A0	P2	API+GPU
B2 位置剖面重测	5 位置 × 3 阅读器, $n=50$	F1 曲线	无	P2	API+GPU
B3 相关研究扩展	3 阅读器 × 方法对	Pearson	B1	P2	复用
C4 预算自适应 (可选)	IDF 分桶调 B , 3 池	召回	C1	可选	本地

执行顺序按依赖与成本排成三个波次。第一波（本周内可完成，除 A0 外全部零 API）：C1 与 C2 并行——两者改同一脚本的不同循环，合并为一次提交；C3 在其落盘后重绘。第一波完成后修订稿即可获得跨数据集消融表与统一矩阵表两张新表与一张升级图，“premature”的第二构成（消融未连成矩阵）即被消解。第二波：A0（API 配额恢复即挂机）与 A1 串行，A1 在 A0 的断点机制上参数化扩展；完成后端到端主表换血，“premature”的第一构成消解过半。第三波（视审稿窗口与预算）：A2 与 B1/B2/B3，其中 B 系列共享 GPU 时租与阅读器端点配置，一次搭好后三项连续执行；完成后第三构成（单点依赖）消解，且阅读器侧位置剖面从“借用”升格为“自测”。

总预算量级汇总：API 调用约 $700 + 1,400 + 800 + 2,100 + 750 \approx 5,750$ 次阅读器问答（A0 至 B2 全做的情形；每问输入中位约 1,500 token、输出上限 96 token），本地计算合计不超过单容器一天，GPU 时租为两个本地阅读器服务时长（B 系列内复用）。若预算受限，裁剪顺序为：先砍 C4，再砍 A2（保留 B1 的跨阅读器主张，放弃跨数据集端到端），最后把 B1 的 API 档阅读器从二减一（保留本地开源档与既有 GLM 档，仍有三阅读器中的两个新证据点）。

7 research-repo 对接清单

以下按脚本粒度给出改动清单，全部路径相对 `sieve-paper-package/research-repo/`。改动的共同纪律：不修改 `src/sieve/` 与 `baselines/` 的任何现有行为（选择器实现是论文声明的对象，动它等于换方法）；新增逻辑一律以参数化或新脚本形式叠加；每个新结果文件登记到 `make_numbers_journal.py` 的宏生成链，保证论文引用继续走宏而非手写数字。

1. `scripts/run_journal_analysis.py` (C1+C2, 一个文件两处改动)：其一，把 M3 的池选择从硬编码 QASPER 改为命令行参数 (`--pools qasper,hotpot,2wiki`)，消融配置数

组抽出为模块级常量便于复用；其二，新增 M8 任务“配置 × 预算矩阵”——外层循环遍历消融五配置与基线（复用 M2 的预算循环体），内层复用现有打分与 bootstrap 函数，输出 `results/journal_matrix.json`。预计净增 80–120 行。

2. `scripts/run_qa_expanded.py` (A1): 把“前 100 条”的测试集切分参数化为 `--n 100|300`；其余零改动（提示、解码、断点、七方法全部冻结）。
3. `scripts/run_qa_driver.py` (A0/A1/B1): 目标数与窗口已有参数；B1 复用时新增 `--reader` 参数透传给 `llm_query.mjs` 的端点配置。检查点文件按阅读器分目录(`checkpoints/qa_{reader}.jsonl`)避免混写。
4. `scripts/llm_query.mjs` (B1): 抽象出端点/模型/密钥的三元配置表（GLM 既有 + 两个新阅读器 + 可选本地 vLLM 的 OpenAI 兼容端点）；本地档用 vLLM 起 OpenAI 兼容服务即可零改动接入现有调用封装。
5. 新增 `scripts/run_reader_position.py` (B2): 复用 M4 的证据放置构造逻辑（反向使用：放置后不压缩、直接端到端提问），输出每阅读器的位置–F1 曲线数据 `results/reader_position.json`。
6. `scripts/run_correlation.py` (B3): 加 `--by-reader` 分组输出；合并逻辑不变。
7. `scripts/run_qa_cross_dataset.py` (A2, 新脚本): 从 `hotspot/2wiki` 池按固定种子抽 $n=100$ ，方法集四元组（full/head/bm25/sieve），复用 `run_qa_expanded.py` 的提问与度量函数（抽公共模块或直接复制其核心函数，保持协议字符串逐字一致）。
8. `scripts/fig_journal.py` (C3): frontier 图数据源从 M2 单点切换为 `journal_matrix.json` 全矩阵；等预算线分组逻辑新增约 40 行。
9. `scripts/make_numbers_journal.py`: 为每个新结果文件补宏生成段（消融跨池、矩阵、 $n=100/300$ 端到端、多阅读器、位置剖面、扩展相关），宏命名沿用现有 `Abl*/Rec*/QA*` 风格前缀以便 diff 审查。

配套的论文侧（`paper-journal-v2/`）对接：C1/C2 落盘后，`numbers.tex` 重生成并在消融节引用跨池宏；A/B 系列落盘后，端到端节的主表与样本量数字替换、局限一节第一条与第三条边界改写、相关研究节更新。所有替换走 `make_numbers_journal.py`→`numbers.tex` 宏链，写作时禁止手写数字。

8 声明纪律与负结果报告规范

实验扩容最大的风险不是跑不完，而是“数据多了之后挑对自己有利的说”——这恰是实验分析规范（awesome-ai-research-writing 仓库的实验分析 prompt 所内嵌的原则：所有结论必须严格基于输入的数据；严禁编造数据、夸大提升幅度；如果数据中没有明显的优势或趋势，如实描述，不要强行总结显著提升）所禁止的。本节把声明纪律前置为实验设计的一部分，规则如下。

第一，先声明后实验。每个实验单元在运行前登记其“将支撑的论文声明”与“判定标准”（本计划各节已给出，执行时可对照），实验完成后无论结果方向如何，登记的声明按原判定标准兑现或撤回。例如 A1 的登记是：若 SIEVE-head 配对区间半宽收窄至 ± 5 点内且区间跨零，则

论文声明维持“统计持平”并加注 n ；若区间分离，声明升级为方向性优势——两种结局都算完成，但措辞跟着证据走。

第二，负结果是发现，不是失败。BM25 召回更高的既有叙事已经示范了这一点；扩容后的负结果同样按“结构性发现”报告：B1 若出现阅读器异号，报告为“阅读器家族与压缩敏感性的交互”；A2 若多跳数据集端到端退化快于召回，报告为“召回-质量传导率的数据集依赖”，并与相关研究节互相印证。唯一禁止的写法是把负结果藏进附录或不报。

第三，协议冻结与版本登记。提示模板、解码参数、预算定义、池种子在每条路径内冻结；任何必须的改动（例如阅读器换代的 API 不再可用）单独登记为协议版本号，新旧数据不跨版本合并统计。端到端协议的冻结条款已在路径 A 声明，B/C 同理。

第四，宏引用纪律延续。第一阶段审计发生过一次凭印象写错消融数字（43.6 误写为 44.6）的事故并被 numbers.tex 宏核对纠正；扩容后数字数量翻倍，一切进正文的数字必须经 `make_numbers_journal.py` 生成的宏，reviewer 复核脚本同时校验宏值与结果 JSON 的一致性。

第五，与 anonymity 及投稿伦理的衔接。扩容实验全部基于公开基准与自建池，无新数据许可问题；多阅读器 API 使用遵守各服务商条款并如实披露阅读器版本与解码参数；本地阅读器权重与推理配置随仓库发布，保证可复现声明不因阅读器多样性而弱化。

9 完成定义：拒稿意见逐条映射

本计划的验收不以“跑完了多少实验”衡量，而以下表逐条对照：拒稿意见的每个具体构成，在哪个实验完成后、以论文中的哪类证据形式，被认为已回应。此表同时是修订说明信（response letter，若重投或改投时需要）的骨架。

最后给出三档验收口径，供按实际资源停机。最低档（P0 完成：A0 + 第一阶段 v2）：端到端 $n=100$ 落盘、叙事重构完成——此时“premature”的第一构成已实质缩小但未完全消解，适合先行内部评审。标准档（P0+P1：A1 + C1–C3）：矩阵化证据齐备、端到端 $n=300$ ——达到可重投或改投（KBS/ESWA 类）的证据门槛，且两条 premature 构成全部消解。完整档（加 P2）：跨数据集端到端与三阅读器稳健性——使论文对“结构性权衡”的声明具备跨阅读器与跨任务形态的证据面，投稿竞争力最高。三档之间随时可停，已完成的每一格都独立可写——这是本计划与“盲目扩容”的根本区别。

表 2: 拒稿意见构成与补强证据的映射。“章节”指 paper-journal-v2 的对应位置。

拒稿构成	补强实验	完成形态
新颖性不足（第一阶段）	文献审计 + 叙事重构（已完成的 v2）	新标题与 formulation 摘要；相关工作七维设计空间表与 delta 段；贡献列表重排为“形式化 → 方法论 → 发现 → 实例”
端到端规模（ $n=25$ 、单点）	A0+A1	$n=300$ 端到端主表，区间半宽 $\approx \pm 3.3$ F1 点；BM25 进入端到端层
跨数据集端到端缺失	A2	HotpotQA 与 2Wiki 各 $n=100$ 端到端表（视资源）
单阅读器依赖	B1	三阅读器趋势稳定性表/图；“对某阅读器成立”限定词删除或改写
位置剖面借用	B2	自测阅读器侧位置曲线图，替换借用的动机段
消融未成矩阵	C1+C2+C3	三数据集消融表；配置 $\times$ 预算矩阵表；升级版三轴 frontier 图
召回-F1 相关 n 小	A0 扩容 + B3	相关研究更新为 $n=100$ 起步、跨阅读器分组
“More work needed”整体	全部 + 本两阶段文档	修订说明信按本表逐条给出“意见 → 改动 → 证据”三段式回应