

Sieve 拒稿后重构

第一阶段： Novelty 审计报告

逐篇查证 2023–2026 年上下文选择与压缩文献，建立七维可审计对比表，确认 Sieve 相对 Perception Compressor、QASPC、LongLLMLingua 等竞品的真实增量，并给出研究问题、标题与逐节改写方案。

Super Z 研究助手

审计对象：GitHub 43aquaris/academic-paper · paper-journal 2026-09-24 版
拒稿来源：Information Processing & Management (desk rejection, 2026-09)

目录

1 拒稿诊断与本报告的任务	2
1.1 拒稿意见的结构	2
1.2 本报告的任务与方法论约束	2
2 审计方法、检索范围与证据等级	3
2.1 检索渠道与检索日期	3
2.2 证据等级的定义与已知局限	3
3 逐篇方法审计	4
3.1 经典基线（四项）	4
3.2 神经 token 级压缩（四篇）	5
3.3 Training-free 直接竞品（两篇，重点审计）	6
3.4 句子级但需训练（两篇）	6
3.5 预算自适应与外围（两项入表，四项简评）	7
4 七维对比总表	7
5 审计结论：Sieve 的真实增量	9
5.1 已被占领的主张：新颖性红线	9
5.2 仍然站得住的差异：三根支柱	9
5.3 组合新颖性的残余风险与辩护策略	10
6 重构方案：研究问题、标题与逐节改写指令	10
6.1 新研究问题的表述	10
6.2 标题方案	11
6.3 逐节改写指令	12
7 遗留验证事项与证据登记	13
A 证据来源清单	14

1 拒稿诊断与本报告的任务

1.1 拒稿意见的结构

2026 年 9 月, SIEVE 期刊版 (投稿 Information Processing & Management, 2026-09-24 版) 收到编辑直接拒稿 (desk rejection)。拒稿信的核心意见只有两句: 其一, 论文缺乏足够的新颖性 (lack of sufficient novelty); 其二, 所报告的研究结果过于不成熟, 不足以支撑发表 (the research results reported are too premature for publication)。与此同时, 编辑明确确认论文主题落在期刊的范围之内 (falls within the aim and scope of this journal)。这三句话合在一起构成了一份罕见的、高度集中的诊断: 期刊不质疑问题的重要性, 也不质疑写作与格式, 而是把全部否决理由压在两个具体的科学维度上——贡献的增量的真实性, 以及证据链的成熟度。

这一诊断与本论文在 2025–2026 年文献环境中所处的位置直接相关。以 2023 年 LLM-Lingua 与 Selective Context 为起点, 训练无关 (training-free) 的提示与上下文压缩已经从一个空白角落变成了一个快速拥挤的赛道: LongLLMLingua 加入了问题条件化与位置相关的机制, LLM-Lingua-2 引入了数据蒸馏的 token 分类器, Perception Compressor (NAACL 2025 Findings) 明确以 training-free 为主张并纳入问题引导与位置分配, 2026 年出版的 QASPC 则直接以 question-aware、sentence-level、training-free 三个属性作为标题。在这样的环境下, 一篇论文如果把自己定位为“又一个 training-free 压缩器”, 其新颖性主张必然与已有工作大面积重叠。拒稿意见正是这种重叠的反映。

1.2 本报告的任务与方法论约束

本报告是两阶段重构计划的第一阶段, 对应拒稿意见的第一句话。任务只有一个: 以可审计的方式逐篇查证 2023–2026 年的相关文献, 回答“SIEVE 相对于现有工作到底新增了什么”。如果这个问题回答不出来, 正确的后续动作是修改方法本身而不是继续润色表述; 如果能够回答, 则答案将成为论文 v2 版本全部叙事 (标题、摘要、引言、贡献列表、相关工作) 的重建基础。

审计遵循三个方法论约束, 均来自论文写作技能库 (20-ml-paper-writing) 中的引用规范。第一, 绝不凭记忆生成文献事实: 每一篇被审计文献的机制描述都必须能追溯到检索到的原文证据 (摘要、全文或官方代码仓库), 不允许“我记得这篇论文是……”式的判断进入结论。第二, 无法验证的单元格如实标注: 当某篇文献的全文不可得、某个机制细节无法从公开渠道核实时, 相应判定标注为“未验证”并说明原因, 而不是猜测填充。第三, 区分证据等级: 全文与官方代码直接确认的判定记为 A 级, 多源摘要片段交叉确认的记为 B 级, 仅凭单一来源或无法核实的记为 C 级。第 3 节的每张方法卡片末尾都标注了证据等级与来源清单, 附录 A 给出了全部原始链接与检索日期。

第二阶段的任务——回应“结果过于不成熟”的证据补强——由配套的《实验补强计划》单独承担, 两份文件共同构成对拒稿意见的完整回应。需要强调的是, 两份文件之间存在依赖关系: 实验补强的设计必须服务于新颖性重构后所声明的贡献, 而不是盲目扩大实验规模。先定“新在哪里”, 再定“凭什么信”, 这个顺序不可颠倒。

2 审计方法、检索范围与证据等级

2.1 检索渠道与检索日期

全部检索于 2026 年 9 月 29 日完成。检索渠道包括：arXiv（摘要页与 HTML 全文）、ACL Anthology 论文页、ACM Digital Library 条目页（仅元数据与摘要片段）、Semantic Scholar API (api.semanticscholar.org，用于元数据与引用图谱)、OpenAlex API (api.openalex.org)、GitHub 官方代码仓库（Perception Compressor 与 NAACL 2025 综述的 README）、以及通过网页搜索服务获取的出版商页面摘要片段。NAACL 2025 的综述《Prompt Compression for Large Language Models: A Survey》(Li 等) 的论文清单被用作方法谱系的交叉核对源：凡综述清单中属于 hard prompt filtering 与 paraphrasing 两个分支、且与句子级选择相关的方法，均纳入候选审计集。

检索策略围绕 SIEVE 的四个核心组件设计：问题条件化 (question conditioning / question-aware / query-aware)、位置感知 (position-aware / positional bias / reordering)、冗余控制 (redundancy / maximal marginal relevance / diversity)、以及预算与成本 (budget / compression ratio / cost)。对每个组件，检索覆盖 2023–2026 年的 prompt compression、context compression、context selection、retrieval-based compression、training-free compression 与 sentence-level selection 六个关键词族。共执行二十余次针对性检索，原始结果以 JSON 形式存档于审计工作目录，附录 A 列出全部来源 URL。

2.2 证据等级的定义与已知局限

文献判定分为三级。A 级表示机制描述由论文全文、官方摘要或官方代码仓库直接确认，例如 Perception Compressor 的三组件机制 (perception retriever、dual-slope ratio allocator、semi-guided iterative compression) 同时由 arXiv 摘要与官方 GitHub README 的“Relevant LLMs”一节确认——其中明确记载压缩用 LLM 为 LLaMA-2-7B、演示检索用 SentenceBERT (all-mpnet-base-v2) 计算引导问题相似度。B 级表示判定由出版商页面的多个摘要片段交叉确认，但没有全文，例如 QASPC 的 training-free、question-aware、sentence-level 与 clause-level 去冗余四项属性。C 级表示该维度无法从任何公开渠道核实。

本次审计最重要的已知局限是 QASPC (ACM DOI 10.1145/3800227.3800247)。该文全文位于 ACM 付费墙之后，检索期间 ACM Digital Library 对自动化访问返回反爬拦截页，论文没有 arXiv 预印本，Semantic Scholar 与 OpenAlex 的摘要字段均被出版商屏蔽，也未检索到公开代码仓库。因此 QASPC 的打分机制（是否依赖嵌入模型或语言模型）、是否具备位置感知组件、是否有显式预算机制三个维度全部标注为未验证。这一局限在第 7 节被列为最高优先级的遗留验证事项：在获取全文之前，任何关于“SIEVE 优于 QASPC”或“QASPC 与 SIEVE 等价”的断言都不应写入论文。审计能确认的只有下限：QASPC 与 SIEVE 在 training-free、question-aware、sentence-level 三个公开可见的属性上重叠，这已经足以否决“这三个属性的组合是新的”这一类表述。

另有两处范围边界需要说明。第一，soft prompt 家族（GIST、AutoCompressor、ICAE、500xCompressor、xRAG、LLoCO、QGC 等）将上下文压缩为连续向量而非可读文本，与 SIEVE

的离散句子选择属于不同技术路线，正文仅在相关工作定位中简要涉及，不进入七维对比主表。第二，KV cache 层面的方法（H2O、StreamingLLM、FlashAttention、vLLM）作用于模型内部注意力与缓存，与提交前的上下文压缩正交，论文 v1 已正确地将其定位为可组合的独立层面，本次审计不重复展开。

3 逐篇方法审计

本章对十四个方法逐一建立审计卡片。每张卡片包含四项内容：机制描述（选择信号如何计算、在什么粒度上截断）、基础设施需求（运行时必须驻留什么模型或服务）、七维判定（问题条件化 Q、位置感知 P、冗余控制 R、免模型 MF、免训练 TF、句子级完整单元 SL、显式预算与成本刻画 BF），以及证据等级与来源。判定符号：✓ 表示满足，× 表示不满足，* 表示部分满足或存在重要限定，? 表示本次审计无法验证。

3.1 经典基线（四项）

头截断 (head truncation)。保留上下文的前 B 个词。选择信号为零——不做任何计算，位置上隐式地押注“证据集中在开头”。它免模型、免训练、无成本，但既不看问题也不控制冗余；对长上下文模型已知的位置偏差（中间位置的注意力可靠性最低）而言，固定前缀同时丢弃后部证据并把风险集中在模型读取最可靠的位置上，这在 SIEVE 论文中已被用作 frontier 的零成本左端点。七维判定：Q ×，P *（隐式位置押注，非感知），R ×，MF ✓，TF ✓，SL ×（词级硬切），BF ×。证据等级 A（论文内部基线，机制自明）。

随机与跨步选择 (random / stride)。在词预算内均匀随机抽句（两个种子），或每第 k 句保留一句以凑满预算。同样零信号零成本，跨步选择隐式地保留了全文档的均匀位置覆盖，这恰好是无位置先验的下界参照。七维判定：Q ×，P ×（跨步为均匀覆盖而非感知），R ×，MF ✓，TF ✓，SL ✓，BF ×。证据等级 A。

TextRank (2004)。在 IDF 加权余弦相似度图上以 PageRank 中心性排序句子，取排名最高者打包进预算。它是“最强的免模型、免训练、不看问题的摘要器”——冗余通过图结构的间接方式获得部分控制（彼此相似的句子分享中心性，但没有显式惩罚项），不看问题因此对证据召回无能为力。七维判定：Q ×，P ×，R *（隐式，无显式惩罚），MF ✓，TF ✓，SL ✓，BF ×。证据等级 A（经典算法，SIEVE 论文已正确将其纳入基线集）。

BM25 句子排序 (2009) 与 MMR (1998)。BM25 以问题为查询、以句子为文档做相关性排序，是“问题条件化 + 免模型 + 免训练 + 句子级”的最强古典实现，其 IDF 在上下文内部平滑后与 SIEVE 共享语料局部统计。MMR 把抽取形式化为相关性与冗余的边际权衡，是 SIEVE 的直接学术祖先——SIEVE 论文 v1 自己就承认是“MMR 的一个带 IDF 加权与位置先验的特化实例”。两者的七维判定合写：BM25 为 Q ✓，P ×，R ×，MF ✓，TF ✓，SL ✓，BF *（有预算打包，无问题形式化与成本刻画）；MMR 为 Q ✓，P ×，R ✓（显式惩罚项的起源），MF ✓，

TF ✓, SL ✓, BF ×。证据等级 A。这两条卡片在审计中承担特殊角色：它们证明“问题条件化 + 句子级 + 免模型免训练”的组合在 1998–2009 年就已经存在，因此 SIEVE 的新颖性绝不能建立在该组合之上，而必须建立在其后新增的维度上。

3.2 神经 token 级压缩（四篇）

LLMLingua (EMNLP 2023, Jiang 等)。以小语言模型（论文使用 GPT-2 级别打分器）计算 token 困惑度，按困惑度从高到低迭代删除 token，粗到细两阶段在固定 token 预算内搜索压缩方案。选择信号是一次完整的神经前向打分，粒度为 token。基础设施需求：一个与打分器匹配的托管小模型（含对应 tokenizer），粗到细流程需要多次前向。原始版本不看问题（问题无关压缩），后续 LongLLMLingua 才加入问题条件化。七维判定：Q ×, P ×, R ×, MF ×, TF ✓, SL ×, BF ✓（显式 token 预算迭代搜索）。证据等级 A（arXiv 摘要与 SIEVE 论文的同机制 GPT-2 复刻互证）。值得记录的审计细节：SIEVE 论文用 GPT-2 困惑度门（句子粒度、int8、同容器测量）复刻了该机制的成本下界——28.7% 证据召回、每中位上下文 7.5–8.2 秒打分成本，这组数字在后面第 5 节的增量分析中反复使用。

LongLLMLingua (ACL 2024, Jiang 等)。在 LLMLingua 之上加入四个组件：问题过滤（对比困惑度，即问题条件下 token 重要性的重新打分）、文档重排序（按与问题的相关性从高到低重排演示，直接针对 lost-in-the-middle 位置偏差）、token 级预算分配器（线性调度器，按需给不同 token 分配预算）、以及四层粒度的粗到细压缩。这一篇是审计中最关键的“组件重叠”证据：问题条件化与位置感知两项 SIEVE 的核心组件在此已经同时出现，且以 token 粒度实现。七维判定：Q ✓, P ✓（重排 + 位置相关 token 处理），R ×, MF ×（依赖小 LM 打分），TF ✓, SL ×, BF ✓（显式预算分配器）。证据等级 A（ACL Anthology 页面与多个二手技术分析交叉确认）。它相对 SIEVE 的差异在粒度（token 碎片化 vs 完整句子保序）与打分器（托管 GPT-2 vs 纯统计），不在组件清单。

LLMLingua-2 (ACL 2024 Findings, Pan 等)。把压缩重构为 token 分类任务：从 GPT-4 压缩结果蒸馏出 117M 参数的 token 分类器（BERT 级），推理时一次分类决定 token 去留。质量上与 LLMLingua 相当或更好且更快，但引入了训练阶段（数据蒸馏）与一个非通用小模型权重。七维判定：Q ×（任务无关分类器），P ×, R ×, MF ×（117M 神经分类器），TF ×（需要蒸馏训练），SL ×, BF ✓（token 预算控制）。证据等级 A。对 SIEVE 的意义：它把“压缩器自身基础设施”问题推到台前——即便推理侧不需要完整 LLM，仍要托管一个专用网络，这与 SIEVE 的零基础设施角落形成干净对照（SIEVE 论文 limitations 已如实声明没有复刻它，属诚实范围控制）。

Selective Context (EMNLP 2023, Li 等)。按自信息（self-information，由一个因果 LM 计算的 $-\log p$ ）过滤 token、短语或句子三个粒度的低信息单元。它是“用语言模型感知信息量”路线的起点，不看问题（自信息度量的是上下文自身的信息密度而非与问题的相关性）。七维判定：Q ×, P ×, R *（信息密度间接抑制重复），MF ×（需要 LM 计算自信息），TF ✓, SL *

(支持句子粒度但以词组删除为主), BF ×。证据等级 A (SIEVE 论文 v1 相关工作已正确描述其机制)。

3.3 Training-free 直接竞品 (两篇, 重点审计)

Perception Compressor (NAACL 2025 Findings, Tang 等; arXiv:2409.19272)。这是拒稿意见所指“training-free prompt compression 已有大量工作”的最直接证据, 审计详查其官方实现。机制由三个组件构成: 其一, perception retriever 用引导问题 (guiding questions) 与指令作为查询, 通过 SentenceBERT (all-mpnet-base-v2, 约 110M 参数) 计算语义相似度检索最相关的演示并按相关度重排; 其二, dual-slope ratio allocator 依据位置敏感假设动态分配各位置的压缩率与开卷率——这是位置感知组件的显式实现; 其三, semi-guided iterative compression 在 token 级做半引导迭代压缩, 由 LLaMA-2-7B 作为压缩用 LLM 执行。此外, 每个输入问题的引导问题本身需要先用 LLM 生成。实验覆盖 NaturalQuestions、LongBench、MuSiQue。七维判定: Q ✓ (引导问题检索), P ✓ (重排 + dual-slope 位置分配), R × (无显式冗余惩罚), MF × (SentenceBERT + LLaMA-2-7B 双重模型依赖), TF ✓, SL × (token 级压缩, 演示级检索), BF * (ratio allocator 分配压缩率, 无选择成本刻画)。证据等级 A (arXiv 摘要与官方 GitHub README 的“Relevant LLMs”配置节直接互证)。审计结论: 它证明“training-free + question-aware + position-aware”三元组已被占领; SIEVE 相对它的可辩护差异只剩两条——零模型依赖 (纯统计 vs BERT+7B LLM) 与句子级完整单元保序输出 (vs token 碎片化), 两者都是结构性差异而非组件差异。

QASPC (ACM 2025/2026, Chen、Liu、Fu; DOI 10.1145/3800227.3800247)。从可获得的摘要片段确认的属性有四项: training-free、question-aware、两阶段框架、句子级与从句级 (clause-level) 双层过滤并显式以“减少句子与从句两层冗余”为目标。发表日期显示为 2026 年 4 月在线。这意味着 SIEVE 的“training-free + question-aware + sentence-level + 冗余控制”四属性组合已被公开占位——其中冗余控制在 SIEVE 中以 MMR 式惩罚实现, 在 QASPC 中以从句级二次过滤实现, 实现路径不同但问题意识相同。无法验证的维度: 打分机制 (是否依赖嵌入相似度或语言模型)、位置感知、预算与成本刻画——全文在 ACM 付费墙后, 无 arXiv 预印本, 无公开代码, Semantic Scholar 与 OpenAlex 的摘要字段均被出版商屏蔽。七维判定: Q ✓, P ?, R ✓, MF ?, TF ✓, SL ✓ (外加从句粒度), BF ?。证据等级 B (多源摘要片段交叉)。审计结论: 在拿到全文之前, SIEVE 相对 QASPC 唯一可以负责任声明的差异是已测量的零模型依赖与位置先验组件 (若 QASPC 验证后不具备), 以及完整的三轴成本刻画; 论文 v2 的相关工作必须引用并如实标注这一不确定性, 而不是装作它不存在——忽略最近的同名属性竞品是审稿人最容易抓到的硬伤。

3.4 句子级但需训练 (两篇)

RECOMP (ICLR 2024, Xu 等)。在检索与生成之间插入压缩层, 提供两个学习型压缩器: 抽取式压缩器从检索文档中选择有用句子 (训练的双编码器打分), 抽象式压缩器生成文本摘要 (训练的 seq2seq)。它是“句子级抽取 + 问题条件化”的神经学习版本, 质量稳健但需要标注数

据训练专用模型。七维判定：Q ✓，P ×，R ×（抽取式选择隐式抑制重复），MF ×（训练的双编码器），TF ×，SL *（抽取式为句子级，抽象式不保句），BF ×。证据等级 A（OpenReview 页面摘要）。对 SIEVE 的定位价值：它划出了“句子级选择走学习路线”的既有坐标，SIEVE 的差异是不训练任何部件。

CPC (AAAI 2025, Liskavets 等; arXiv:2409.01227)。训练一个上下文感知的句子编码器（以问题-正例-负例三元组对比学习），推理时以编码器分数过滤句子。2026 年其作者群另有任务无关的 TPC 扩展。七维判定：Q ✓（训练信号来自问题对），P ×，R *（上下文感知编码部分覆盖），MF ×，TF ×，SL ✓，BF ×。证据等级 A（AAAI 页面摘要）。它进一步坐实：句子级 + 问题感知的学习型方案在 2025 年已成熟，纯统计路线的空间恰好在于零训练与零基础设施。

3.5 预算自适应与外围（两项入表，四项简评）

AdaComp (arXiv:2409.01579, Zhang 等)。面向 RAG 的抽取式上下文压缩，核心是自适应压缩率：依据问题复杂度与检索质量动态决定保留的文档数量，动机是复杂多跳问题需要更多文档而低质量检索需要更多冗余。选择单元为文档级，信号来自检索器分数。七维判定：Q ✓，P ×，R ×，MF *（依赖检索器但无需额外模型），TF ✓，SL ×（文档级），BF ✓（自适应压缩率是其核心贡献）。证据等级 A（arXiv 摘要）。它证明“预算不固定、按问题自适应”的想法也已被占位——但自适应的是文档数而非词预算内的多目标权衡，与 SIEVE 的显式三目标 formulation 仍然不同。

外围方法简评（不入主表）。QUITO（arXiv 2024-08）用问题对上下文的注意力分数过滤无用内容，机制上需要完整 LLM 前向，属模型依赖的 question-aware 过滤。QGC（ACL 2024）是 query 引导的软压缩器（编码器-解码器路线），证明问题引导思想也进入了 soft prompt 分支。CompAct（EMNLP 2024）以主动压缩结合小摘要模型做转写式压缩。Divide-Prompt-Refine（2026-05 arXiv）与 SmartChunk（2026）是检索可见的最新 training-free / query-adaptive 工作，尚待正式版本核实机制，列入第 7 节的跟踪清单。这批文献的共同作用是把“问题引导压缩”从单点想法变成 2024–2026 年的密集研究线，SIEVE 的 novelty 表述必须在这个背景下重新校准。

4 七维对比总表

表 1 汇总全部十四项方法的七维判定。七个维度直接对应 SIEVE 的组件清单与设计主张：Q（问题条件化）、P（位置感知）、R（冗余控制）、MF（免模型：运行时零神经/嵌入模型）、TF（免训练）、SL（句子级完整单元输出）、BF（显式预算形式化与压缩器成本刻画）。符号沿用第 3 节：✓ 满足，× 不满足，* 部分满足或有重要限定，? 本次审计无法验证。

读表的方式决定结论的走向，因此这里把三种读法都摆出来并逐一检验。第一种读法是清单式读法：SIEVE 是表中唯一在七个维度上全部打 ✓ 的方法。这个读法在形式上成立，但它是审计中最危险的读法——每一行竞品都只是在个别维度上缺格，而“把别人缺的格子补齐”恰恰是

表 1: 上下文选择与压缩方法的七维对比。判定依据见第 3 节各方法卡片；Q = 问题条件化，P = 位置感知，R = 冗余控制，MF = 免模型，TF = 免训练，SL = 句子级完整单元，BF = 显式预算与成本刻画。* 表示部分满足，? 表示未验证（QASPC 全文不可得）。

方法	年份	Q	P	R	MF	TF	SL	BF
MMR	1998	✓	×	✓	✓	✓	✓	×
BM25	2009	✓	×	×	✓	✓	✓	*
TextRank	2004	×	×	*	✓	✓	✓	×
头截断/随机/跨步	—	×	×	×	✓	✓	*	×
Selective Context	2023	×	×	*	×	✓	*	×
LLMLingua	2023	×	×	×	×	✓	×	✓
LongLLMLingua	2024	✓	✓	×	×	✓	×	✓
LLMLingua-2	2024	×	×	×	×	×	×	✓
RECOMP	2024	✓	×	×	×	×	*	×
Perception Compressor	2025	✓	✓	×	×	✓	×	*
CPC	2025	✓	×	*	×	×	✓	×
AdaComp	2024	✓	×	×	*	✓	×	✓
QASPC	2026	✓	?	✓	?	✓	✓	?
SIEVE	本作	✓	✓	✓	✓	✓	✓	✓

组合式新颖性的定义，正是 IP&MMM 拒稿意见所否定的那一类主张。审稿人对照此表的标准反问是现成的：LongLLMLingua 已同时具备 Q 与 P，QASPC 已同时具备 Q、R 与 SL，MMR 早在 1998 年就具备 R，把四者的长处拼在一起为什么构成新的科学贡献？清单式读法无法回答这个问题，论文 v2 必须放弃它作为主要新颖性表述。

第二种读法是结构式读法：观察维度之间的联合分布而非逐格比较。表中 MF 列揭示了一个所有 training-free 竞品共有的结构特征——Perception Compressor 需要 SentenceBERT 加 LLaMA-2-7B，LongLLMLingua 与 LLMLingua 需要托管小 LM，LLMLingua-2 需要训练出的分类器，RECOMP 与 CPC 需要训练的编码器。也就是说，“training-free”在 2024–2026 年文献中的实际含义是“免训练但仍需模型”，真正的免模型坐标全部落在古典方法区（BM25、TextRank、MMR）。这把设计空间切成一个 2×2 结构：问题条件化与位置/冗余感知的组件 richness 在纵轴上，基础设施依赖在横轴上；现有工作要么富组件但重基础设施（右上象限），要么轻基础设施但组件贫乏（左下象限），左上象限——组件较全且零模型依赖——在审计范围内确实没有先例占位。这个象限空缺是表 1 提供的最有价值的一张图，也是 SIEVE 可以负责任声明的定位。

第三种读法是方法论读法：BF 列几乎整列为 × 或 *。现有文献在“压缩到多少”上有预算机制（LLMLingua 家族的迭代搜索、AdaComp 的自适应率），但没有一篇把“压缩器自身的计算成本”作为独立测量轴与质量、压缩率并列报告，更没有以此为轴做 frontier 分析。SIEVE 论文 v1 的三轴框架（质量–压缩率–选择成本，含同硬件 GPT-2 门复刻的 255–320 倍成本对照）在审计范围内没有发现先例。这是比任何单个组件都更稳的差异点，因为它不是组件而是评估方法论，且天然容纳后续方法（任何压缩器都能被摆上这条 frontier 被定价）。

三种读法合起来给出论文 v2 的叙事重建路径：放弃清单式主张，以结构式定位（左上象限的零基础设施选择器）为主张核心，以方法论读法（三轴 frontier 作为该设计空间的测量标准）为第二主张，把组件贡献降级为 instantiation 细节。第 5 节把这个路径展开为具体的表述规则。

5 审计结论：Sieve 的真实增量

5.1 已被占领的主张：新颖性红线

审计的第一个产出是一份“不能再作为主要新颖性表述”的清单。以下六类表述在 2023–2026 年文献中都有明确先例，任何一条若出现在论文 v2 的摘要、引言或贡献列表的领句位置，都会立即暴露给熟悉文献的审稿人，其效果等同于重复 IP&MMM 已经给出的否决理由。

第一，“训练无关的提示/上下文压缩”。Perception Compressor 的标题即为 A Training-Free Prompt Compression Framework (NAACL 2025 Findings)，QASPC 摘要自述 training-free，NAACL 2025 综述已经把这一分支系统化成图谱。这个词组在 2026 年只能作为限定语使用，不能作为贡献。第二，“问题感知/问题条件化压缩”。LongLLMLingua 的对比困惑度、Perception Compressor 的引导问题检索、QASPC、QUITO、QGC、RECOMP 全部具备。第三，“位置感知压缩”。LongLLMLingua 的文档重排与 Perception Compressor 的 dual-slope 位置分配器是两个独立先例，且都明确以 lost-in-the-middle 为动机。第四，“句子级选择”。QASPC（外加从句级）、RECOMP 抽取式、CPC、TextRank、MMR。第五，“冗余控制”。MMR (1998) 是显式惩罚项的起源，QASPC 在两层粒度上实现。第六，“自适应预算”。AdaComp 的核心贡献即自适应压缩率，LLMLingua 家族有完整的预算搜索机制。

这份红线的直接推论是：SIEVE v1 标题所堆叠的全部定语——Training-Free、Model-Free、Question-Conditioned、Context Compression——每个词单独或两两组合都已被占位。标题必须在重构后收窄到先例未覆盖的层面（formulation 或 frontier），第 6.2 节给出候选。

5.2 仍然站得住的差异：三根支柱

审计确认 SIEVE 有三根在现有文献中找不到先例的支柱，它们应该取代组件清单成为 v2 的贡献骨架。

支柱一：零模型依赖的结构化定位。全部 training-free 竞品的实际基础设施是：Perception Compressor 需要驻留 LLaMA-2-7B（压缩）加 SentenceBERT（检索）并预生成引导问题；LongLLMLingua 与 LLMLingua 需要托管小 LM 并执行多次前向；QASPC 的机制未知但属性与上述家族一致。SIEVE 的运行是纯 NumPy 统计，在 CPU 单核上以毫秒计（6,000 词上下文 53.7ms），与 GPT-2 门的同硬件对照是 255–320 倍的量级差。这不是渐进改进而是类别差异：免模型意味着免 GPU、免 tokenizer、免权重分发、免模型版本管理，部署面从“有一个推理服务”扩展到“有一段 Python”。审计同时给出这条支柱的防守要点：BM25 同样免模型，因此 v2 必须把主张精确表述为“在免模型象限内首次引入位置感知与冗余控制组件并给出完整三轴刻画”，而非“免模型压缩”本身——后者会被 BM25 一句反杀。

支柱二：显式的三目标联合选择形式化。MMR 形式化了相关性-冗余二元权衡，LongLLM-Lingua 与 Perception Compressor 实现了位置机制但未形式化为选择目标，AdaComp 自适应的是预算规模而非目标结构。“在词预算下联合优化相关性覆盖、位置可靠性分配与冗余惩罚”这一问题表述在审计范围内没有先例；SIEVE 论文 v1 的 Problem formulation 一节（含三向权衡与选择成本核算小节）实际上已经写了这个形式化，但它被埋在方法叙事之下、且没有被标题与摘要领句。v2 的工作是把它从论文第三节的正文提升为论文的身份本身。

支柱三：三轴 frontier 评估方法论与结构性发现。压缩器自身成本作为独立测量轴在审计范围内无先例（BF 列全空）；同硬件神经门复刻给出的是“该机制族的成本下界”这一可复用测量物；而 BM25 原始召回高于 SIEVE 的负结果被正面解释为相关性目标与位置/冗余目标之间的 Pareto 权衡，配合消融（relevance-only 召回 43.6% 对全配置 36.2%，flat 位置先验回升至 43.3%）与外部 BM25（43.1%）的相互印证，构成一个“不同选择目标产生结构性 trade-off”的发现，而不仅是“我们的方法比基线好”。这条支柱的额外价值在于它是可扩展的：后续任何压缩器（包括 QASPC 若公开机制）都可以被摆上同一条 frontier 定价，论文由单点方法变成测量框架。

5.3 组合新颖性的残余风险与辩护策略

三根支柱并不能完全消除审稿风险，残余风险集中在两点，v2 需要预先布防。第一点是“左上象限空缺可能只是无人感兴趣而非无人做过”：免模型象限的组件贫乏或许反映学界共识——统计信号做不了位置与冗余。SIEVE 的辩护材料恰好是论文已有的实验：位置先验的消融（全配置 36.2% 对 flat 先验 43.3%）与跨数据集迁移证明统计组件确实在做可测量的工作，而不是摆设；同时其局限（词汇覆盖条件、语义改写鲁棒性弱）在 v1 的形式化分析中已有诚实边界。辩护句式应当是“这个角落空缺是因为它需要回答一个别人没有问的问题：多目标选择在零基础设施约束下还剩多少可用性”，而不是“没人做过所以新”。

第二点是三根支柱之间的依赖：支柱一（零模型）的对手是 BM25，支柱二（formulation）的对手是 MMR，支柱三（frontier）的对手是无——三者单独看都面临“和 X 比新在哪”的追问，合起来才构成“用零基础设施的 instantiation 回答一个显式形式化的多目标选择问题，并以三轴方法论刻画整个设计空间”的完整闭环。因此 v2 的贡献列表必须按“形式化 → 方法论 → 实证发现 → instantiation → 可复现工件”的顺序重写，任何把 instantiation（SIEVE 本身）放在第一条的写法都会把论文重新推回“又一个压缩器”的判决区。摘要与引言的领句同理。这套表述规则连同标题方案，在第 6 节落实为逐节改写指令。

6 重构方案：研究问题、标题与逐节改写指令

6.1 新研究问题的表述

拒稿诊断指出，v1 把研究问题写成了“能否在不训练模型的情况下压缩上下文”，这个问题已被 2023–2026 年文献大量回答。审计确认了更准确的问题定位：现有工作没有回答的是“选择目标的结构”与“选择成本的地位”。据此，v2 的研究问题重述为：

(中文表述) 上下文选择能否被形式化为一个显式的信息选择问题——在固定词预算下联合核算相关性覆盖、位置可靠性分配与冗余惩罚，并把选择器自身的计算成本纳入约束？由此产生的选择器族，在质量-压缩率-成本的测度上，相对于词汇方法 (BM25)、统计方法 (SIEVE) 与神经方法 (困惑度门) 各落在何处；不同选择目标之间是否存在结构性权衡？

(English) *Can context selection be formulated as an explicit information-selection problem that jointly accounts for relevance coverage, positional reliability, and redundancy under a fixed word budget, with the selector's own computational cost treated as a first-class constraint? Where do the resulting selector families sit on the quality-compression-cost frontier relative to lexical, statistical, and neural scorers, and do distinct selection objectives induce structural trade-offs?*

这一表述的三处关键改动值得点名。其一，主语从方法换成了问题：被研究的对象是“选择问题的形式化”，SIEVE 只是它的一个 instantiation，这直接回应“组合式新颖性”的指控。其二，位置项被显式命名为“位置可靠性分配”而非“位置感知”，与 LongLLMLingua/Perception Compressor 的“位置机制”在措辞上区分开：它们把位置当作重排或分配压缩率的启发式，SIEVE 把位置当作与相关性和冗余并列的选择目标并给出理论刻画 (v1 的 reliability allocation 小节已有此基础)。其三，成本进入约束集合：“选择器自身的成本”在问题陈述里就出现，而不是拖到效率章节才补——这是三轴方法论在问题层面的对应物。

6.2 标题方案

v1 标题堆叠了十余个定语，编辑看到的“新东西是什么”因此被稀释。按第 6.1 节的新研究问题，给出三个候选，均收窄到先例未覆盖的层面：

1. **Budgeted Question-Conditioned Information Selection for Training-Free Long-Context Compression**——formulation 层面命名，“budgeted”与“information selection”对应支柱二，副属性 training-free 保留为限定语。审计范围内未检索到同构标题；最接近的 QASPC 标题不含 budget 与 selection 问题形式。
2. **Relevance, Position, and Redundancy under a Word Budget: A Model-Free Selector and the Accuracy-Compression-Cost Frontier**——三目标 + frontier 双命名，直接把支柱二与支柱三抬进标题，“Model-Free Selector”明确差异化定位。长度可接受（不超过 v1）。
3. **The Zero-Infrastructure Corner of Context Compression: Budgeted Statistical Selection on the Accuracy-Compression-Cost Frontier**——象限定位命名，差异化最锐利，但“corner”的修辞比前两者更口语化，期刊偏好下略险。

推荐方案 1 作为工作标题、方案 2 作为备选，最终定稿在第二阶段实验结果落定后确认（届时若多 reader 稳健性成立，frontier 主张的分量变化可能影响取舍）。无论选哪个，v1 标

题中的“Efficient Long-Context LLM Inference”与“Frontier Study of Model-Free Information Selection”两个尾巴应当整体放弃——前者是赛道通用词，后者把 frontier 降低为副标题装饰。

6.3 逐节改写指令

以下指令以“改动什么、为什么、怎么改”的格式给出，全部对应第 5 节的支柱结构。

摘要 (Abstract)。 v1 摘要首句是 “We study how far question-conditioned, model-free information selection can move the frontier... using SIEVE, a training-free sentence selector”——方法先行。v2 首句改为 formulation 先行：先给出“显式三目标预算选择问题”的一句话陈述，第二句才引入 SIEVE 作为其零基础设施 instantiation。BM25 负结果在 v1 摘要中已经诚实出现 (“trades raw recall for positional reliability”)，保留并把措辞升级为“结构性权衡”：“the full selector trades raw recall for placement and diversity, a structural trade-off the relevance-only corner of the design space cannot reach”。神经门对照保留 255–320 倍数字（这是支柱一与支柱三的硬证据）。摘要末句 “a low-cost reference point” 是 v1 里最有价值的一句，保留并前置分量。

引言 (Introduction)。 v1 引言第二段把压缩机版图分为“神经侧”与“截断侧”并指出中间地带未被系统刻画——这个“未映射区域”的叙事方向是对的，但把该区域定义为 “compressors that consult the question, cost milliseconds, and require no model at all”，即以 SIEVE 的属性定义区域，有循环论证之嫌。v2 改为以 taxonomy 表的 2×2 结构定义区域（组件丰富度 $\times$ 基础设施依赖），并引用 QASPC 与 Perception Compressor 说明 “training-free” 的通行含义是“免训练但带模型”，从而“零模型象限”是一个真实的、有先例环绕的空缺。v1 第三段 (“A natural objection precedes the study”) 是全文最好的一段——它把 BM25 反对意见主动摆上台面并给出结构性回答，v2 保留并进一步升格为引言的骨架段落。贡献列表按第 5 节的顺序重排：形式化第一、frontier 方法论第二、实证发现（含 Pareto 权衡与门对照）第三、instantiation 与理论第四、可复现工件第五。

相关工作 (Related Work)。 这是 v2 改动最大的一节。v1 只有四段（神经 token 打分、注意力与缓存、经典选择、位置偏差），缺三样东西：2024–2026 竞品的正面处理、taxonomy 对比表、以及 delta 声明。v2 结构改为五段加一表：(1) 神经 token 级家族 (LLMLingua/LongLLMLingua/LLMLingua-2/Selective Context)，补齐各机制的组件归属；(2) training-free 竞品专段——Perception Compressor 与 QASPC 必须出现，前者如实描述其 SentenceBERT+LLaMA-2-7B 依赖（引官方仓库），后者如实标注 “mechanism behind paywall, properties as stated”；(3) 句子级学习路线 (RECOMP、CPC) 与预算自适应 (AdaComp)；(4) 经典选择传统 (MMR/BM25/TextRank)，保持 v1 已有的“SIEVE 是 MMR 特化”的诚实定位；(5) delta 声明段，用一句话把三根支柱说清。表 1 的七维表以论文表 1 的形式进入本节（列头改用论文语言），这张表同时服务于审稿人 (novelty 可审计) 与读者（设计空间地图）。

BM25 的定位升级。 v1 已把 BM25 称作“任何选择器机制都必须证明自身价值的参照点”，方向正确但埋在 baselines 小节。v2 在三处同步升格：baselines 小节保留机制描述；主结果节把 BM25 与 relevance-only 消融的互证（43.1% 与 43.6% 的外部-内部一致）提升为单独的发现段（“两个独立实现的相关性打分在同一预算下收敛到同一召回，说明相关性是这个设计空间的可靠地板，而 SIEVE 的增量是用召回换取放置与多样性”）；讨论或结论节把“不同选择目标产生结构性 trade-off”与 frontier 图连接。QASPC 若在补查后确认无位置组件，此处可加一句对照。

局限与结论 (Limitations / Conclusion)。 limitations 的五条边界（单 reader、n=25、GPT-2 门非完整 LLMLingua、位置剖面借用自 prior work、句子粒度限制极端压缩率）全部保留——诚实边界是 v1 的资产而非负债。新增一条：与 QASPC 的机制级对比在写作时不可得，已在修订说明中标注。结论的收束句从“SIEVE 是零成本第一级”升级为“本研究的产出是一个形式化、一个测量框架与一个 instantiation；任何后续压缩器（神经或统计）都可以在这条三轴 frontier 上被定价”——把论文的遗产从方法转移到框架。与第二阶段实验计划的衔接（n=100 端到端协议已随仓库发布、多 reader、完整消融矩阵）写入 limitations 的相应条目，使“premature”批评在下一版有明确的、已开工的回应。

Highlights。 v1 highlights 的五条中两条以方法属性开头（“A training-free...”），与红线冲突。v2 重写为：formulation 一条、frontier/权衡一条、零基础设施量级一条（53.7 ms 对 255-320 倍）、跨数据集证据一条、可复现一条，字符数继续遵守 85 上限。

7 遗留验证事项与证据登记

审计在三个位置留下未闭合的验证环，按优先级登记如下。这些事项不阻塞论文 v2 的写作——改写指令已按“可确认下限”设计——但在投稿前应尽量闭合，尤其是第一项。

P1: QASPC 全文获取与机制补查。 当前七维表中 QASPC 有三个？（P、MF、BF）。闭合路径：通过机构订阅或 ACM 个人访问获取 DOI 10.1145/3800227.3800247 全文，补查三点——打分信号（统计/嵌入/语言模型）、是否有任何位置机制、预算如何设定。补查结果直接决定两处表述的措辞：相关工作 delta 段的差异化声明，以及“左上象限空缺”主张的强度。若 QASPC 确为纯统计实现，则 SIEVE 的差异化将收敛到位置先验、三轴刻画与跨数据集证据三件套，formulation 与 frontier 两根支柱不受影响；若其依赖嵌入模型，象限主张完整成立。

P2: 2026 最新工作的正式版跟踪。 检索中出现的 Divide-Prompt-Refine（arXiv 2026-05, training-free、structure-aware）与 SmartChunk（query-adaptive 分块压缩）在审计时仅见预印本描述，机制细节不足以判定七维。建议在 v2 定稿前复查其正式出版版本；若其中任何一个具备“零模型 + 问题条件化 + 预算形式化”组合，需要进入对比表并调整 delta 声明。同类跟踪项：QUITO 的注意力过滤机制在正式发表后的定位变化。

P3: 论文 v1 若干数字与 v2 写作的对应关系。 本次审计已核对 numbers.tex 的关键宏：消融（AblSie 36.2、AblNoPos 43.3、AblRelOnly 43.6、AblNoQ 19.9、AblNoRed 36.3）、BM25（RecQBm 43.1）、GPT-2 门（GateRecall 28.7、GateN 100、GateLatMedCtxS 8.2、GateSieRatioSixk 255、GateSieRatioMed 320）、配对增益（PairQSH 12.8、PairHSH 44.8、PairWSH 22.8）、端到端样

本量 (QAN 25) 与总记录数 (TotalRecords 1600)。v2 写作中所有引用上述数字的句子必须继续从 numbers.tex 宏展开, 禁止手写数字——本次审计过程中已发生过一次凭印象写错消融数字 (43.6 被误写为 44.6) 并被宏核对纠正的事故, 该事故本身即证明宏引用纪律的必要性。

检索结果的存档说明。全部二十余次检索的原始 JSON、抓取的 arXiv 摘要页、GitHub README 与综述论文清单保存于审计工作目录 novelty-audit/searches/, 可按 URL 复核。附录 A 的来源清单与之一一对应。任何后续 agent 或作者本人复核本报告的判定时, 应从附录 URL 出发重走证据链, 而不是信任本报告的转述——这是可审计性的本义, 也是这套流程区别于“AI 生成文献综述”的地方。

A 证据来源清单

以下为本次审计引用的全部文献与证据来源, 检索日期均为 2026-09-29。证据等级: [A] 全文/官方摘要/官方代码直接确认; [B] 多源摘要片段交叉确认; [C] 不可验证。

被审计文献

- [1] LLMingua: Compressing Prompts for Accelerated Inference of Large Language Models. Jiang et al., EMNLP 2023. <https://aclanthology.org/2023.emnlp-main.825/> [A]
- [2] LongLLMingua: Accelerating and Enhancing LLMs in Long Context Scenarios via Prompt Compression. Jiang et al., ACL 2024. <https://aclanthology.org/2024.acl-long.91/> [A]
- [3] LLMingua-2: Data Distillation for Efficient and Faithful Task-Agnostic Prompt Compression. Pan et al., ACL 2024 Findings. <https://aclanthology.org/2024.findings-acl.57/> [A]
- [4] Compressing Context to Enhance Inference Efficiency of Large Language Models (Selective Context). Li et al., EMNLP 2023. <https://aclanthology.org/2023.emnlp-main.391/> [A]
- [5] Perception Compressor: A Training-Free Prompt Compression Framework in Long Context Scenarios. Tang et al., NAACL 2025 Findings. arXiv:2409.19272; 摘要页 <https://arxiv.org/abs/2409.19272>; 官方代码 <https://github.com/Twilightaaa/PerceptionCompressor> (README 记载: LLaMA-2-7B 压缩、SentenceBERT all-mpnet-base-v2 相似度、LongChat-7B/LLaMA-3-8B 目标模型) [A]
- [6] QASPC: Question-Aware Sentence-Level Prompt Compression. Chen, Liu, Fu. ACM DOI 10.1145/3800227.3800247, 在线日期 2026-04-29。元数据经 Semantic Scholar API (paperId 96e178c8...) 与 OpenAlex API 交叉确认; 摘要片段来自 ACM DL 检索快照; 全文付费墙不可得 [B]

- [7] RECOMP: Improving Retrieval-Augmented LMs with Compression and Selective Augmentation. Xu et al., ICLR 2024. <https://openreview.net/forum?id=xjdzfPscOW> (检索入口 openreview.net) [A]
- [8] Prompt Compression with Context-Aware Sentence Encoding for Fast and Improved LLM Inference (CPC). Liskavets et al., AAAI 2025. arXiv:2409.01227; 任务无关扩展 TPC 见 OpenReview (TpGcX9UTOt) [A]
- [9] AdaComp: Extractive Context Compression with Adaptive Predictor for Retrieval-Augmented Large Language Models. Zhang et al., arXiv:2409.01579 [A]
- [10] Prompt Compression for Large Language Models: A Survey. Li et al., NAACL 2025 Main (Selected Oral). 论文清单仓库 <https://github.com/ZongqianLi/Prompt-Compression-Survey> (用于方法谱系交叉核对) [A]
- [11] The Use of MMR, Diversity-Based Reranking for Reordering Documents and Producing Summaries. Carbonell & Goldstein, SIGIR 1998 (经典, 机制自明) [A]
- [12] The Probabilistic Relevance Framework: BM25 and Beyond. Robertson & Zaragoza, 2009 (经典, 机制自明) [A]
- [13] TextRank: Bringing Order into Texts. Mihalcea & Tarau, 2004 (经典, 机制自明) [A]
- [14] Lost in the Middle: How Language Models Use Long Contexts. Liu et al., TACL 2024 (位置偏差背景文献, SIEVE 论文 v1 已引用) [A]

外围参考 (未入主表)

- [1] QUITO: Accelerating Long-Context Reasoning through Question-Guided Context Compression (注意力过滤路线). arXiv 2024-08 [B]
- [2] Retaining Key Information under High Compression Ratios: Query-Guided Compressor for LLMs (QGC). ACL 2024 (软压缩分支) [A]
- [3] CompAct: Compressing Retrieved Documents Actively for Question Answering. EMNLP 2024 (转写式压缩) [A]
- [4] 软提示家族条目: GIST (ICLR 2024)、AutoCompressor (EMNLP 2023)、ICAE (ICLR 2024)、500xCompressor (arXiv:2408.03094)、xRAG、LLoCO (EMNLP 2024)、COCOM ——均引自综述清单 [A]
- [5] Divide-Prompt-Refine (arXiv 2026-05, training-free、structure-aware) 与 SmartChunk Retrieval (query-adaptive 分块) ——正式版待跟踪 [C]

论文 v1 内部来源

- [1] SIEVE 期刊版源文件: `sieve-paper-package/paper-journal/main.tex` (1,812 行, 2026-09-24 提交 2376d2b)

- [2] 数据宏:`sieve-paper-package/paper-journal/numbers.tex`(全部数字引用的权威来源)
- [3] IP&MMM 投稿四件套与匿名稿 (提交 db6cbab, 本次重构的对象为其基础版本)